

Rapport d'Analyse Statistique – Résumé des Analyses et Interprétations

I Analyse statistique de l'influence de la météo sur les accidents de la route aux États-Unis

1. Introduction

Ce rapport présente une analyse statistique avancée des accidents de la route aux États-Unis à partir d'un jeu de données réel. L'objectif principal est d'identifier les facteurs influençant la gravité des accidents, en particulier les conditions météorologiques et certaines variables environnementales, à l'aide de statistiques descriptives, de tests statistiques et de méthodes analytiques avancées.

2. Préparation et description des données

Les données ont été importées à partir d'un fichier CSV. La variable temporelle *Start_Time* a été convertie au format date afin d'extraire l'année, le mois et l'heure de l'accident. Cette étape permet d'effectuer des analyses temporelles et d'améliorer la compréhension du contexte des accidents.

3. Statistiques descriptives globales

L'analyse descriptive de la variable *Severity* montre que la gravité moyenne des accidents est modérée, avec une concentration majoritaire autour des niveaux 2 et 3. Cela indique que la plupart des accidents entraînent des conséquences limitées, même si des accidents plus graves existent.

Les statistiques descriptives des variables numériques *Distance(mi)*, *Visibility(mi)* et *Temperature(F)* révèlent une variabilité notable. Cette dispersion traduit la diversité des conditions environnementales dans lesquelles les accidents se produisent, justifiant la nécessité d'un nettoyage des données avant toute analyse avancée.

4. Nettoyage des données : suppression des valeurs extrêmes

Avant d'effectuer les analyses statistiques avancées, un nettoyage des valeurs extrêmes a été réalisé afin de réduire l'influence des outliers. La méthode de l'intervalle interquartile (IQR) a été utilisée.

Dans un premier temps, la variable *Distance(mi)* a été nettoyée en supprimant les valeurs situées en dehors de l'intervalle $[Q1 - 1.5 \times IQR; Q3 + 1.5 \times IQR]$. Ensuite, le même principe a été appliqué aux variables *Distance(mi)*, *Visibility(mi)* et *Temperature(F)* sur une copie du jeu de données.

Après ce nettoyage, les statistiques descriptives montrent que :

- La majorité des accidents se produisent sur de très courtes distances (entre 0 et 0,02 mile), avec un écart-type très faible, indiquant la suppression efficace des valeurs extrêmes.
- La visibilité est fortement concentrée autour de 10 miles, ce qui suggère que les observations aberrantes ont été éliminées.
- La température présente une moyenne d'environ 67,15°F avec un écart-type de 15,41, traduisant une distribution plus cohérente et réaliste.

Ce nettoyage améliore la fiabilité des analyses statistiques et permet l'utilisation de méthodes avancées telles que la PCA ou la régression.

5. Analyse de la distribution : asymétrie et aplatissement

L'analyse de la distribution de la variable *Distance(mi)* après nettoyage montre une légère asymétrie à droite (skewness = 0,118) et un aplatissement modéré (kurtosis = -1,408). Ces résultats indiquent que les données sont désormais concentrées autour des distances courtes, avec peu de valeurs extrêmes, ce qui confirme leur adéquation pour des analyses statistiques avancées.

6. Analyse temporelle des accidents

Une analyse exploratoire de la distribution des accidents par mois et par heure a été réalisée. Les résultats mettent en évidence des variations temporelles, suggérant une saisonnalité ainsi que des pics d'accidents à certaines heures de la journée. Ces tendances temporelles indiquent que le moment de survenue de l'accident peut jouer un rôle important dans la dynamique globale des accidents.

7. Relation entre météo et gravité : Test du Khi²

Pour étudier la relation entre la gravité des accidents et les conditions météorologiques, les cinq conditions météo les plus fréquentes ont été sélectionnées. Une table de contingence entre *Weather_Condition* et *Severity* a été construite, puis un test du Khi² a été appliqué.

Les résultats du test montrent une statistique χ^2 d'environ 457,4 avec une p-value extrêmement faible ($p < 0,001$). Ce résultat indique une association statistiquement significative entre les conditions météorologiques et la gravité des accidents. Une heatmap normalisée a été utilisée pour visualiser la répartition des niveaux de gravité selon chaque condition météo, facilitant l'identification des situations associées à des accidents plus graves.

8. Comparaison pluie vs temps clair : Test de Mann–Whitney

Un test non paramétrique de Mann–Whitney a été effectué afin de comparer la gravité des accidents survenus sous la pluie et par temps clair. Ce test est particulièrement adapté car la variable *Severity* est ordinale.

Les résultats montrent une p-value extrêmement faible ($p < 0,001$), indiquant une différence statistiquement significative entre les deux conditions. Les accidents survenant sous la pluie présentent globalement une gravité plus élevée que ceux observés par temps clair, soulignant l'impact négatif des conditions pluvieuses sur la sécurité routière.

9. Comparaison multi-météo : Analyse de variance (ANOVA)

Afin d'analyser simultanément l'effet de plusieurs conditions météorologiques, une ANOVA à un facteur a été réalisée en comparant trois groupes : temps clair, pluie et neige.

Les résultats montrent une statistique F d'environ 244,6 avec une p-value très faible ($p < 0,001$). Cela confirme l'existence de différences statistiquement significatives de la gravité des accidents selon les conditions météorologiques. Ce test met en évidence l'influence marquée de la météo, notamment dans des conditions défavorables telles que la pluie et la neige.

9. Conclusion générale

L'ensemble des analyses réalisées montre que la gravité des accidents de la route aux États-Unis est fortement influencée par les conditions météorologiques. Les statistiques descriptives, le nettoyage des données, l'analyse de distribution et les tests statistiques (χ^2 , Mann–Whitney et ANOVA) confirment l'existence de relations significatives entre la météo et la sévérité des accidents.

Ces résultats soulignent l'importance de prendre en compte les conditions météorologiques dans les politiques de prévention routière et ouvrent la voie à des analyses plus avancées, telles que des modèles prédictifs, afin d'anticiper les situations à risque élevé et d'améliorer la sécurité routière.

II Analyse Géographique des Accidents de la Route

1. Statistiques descriptives de la localisation

- Les coordonnées des accidents (Start_Lat, Start_Lng) varient entre :
 - Latitude : **25,43° à 48,19°**
 - Longitude : **-123,81° à -70,57°**
- La latitude moyenne est **35,93°**, et la longitude moyenne est **-97,59°**.
- L'écart-type élevé traduit la **diversité géographique des accidents** sur l'ensemble des États-Unis.

2. Corrélation entre localisation et gravité

- Spearman corrélation :
 - Latitude vs Severity : $-0,000082$, $p = 0,954$ → **aucune corrélation significative**
 - Longitude vs Severity : $-0,0415$, $p < 0,001$ → **faible corrélation statistiquement significative**
- **Interprétation** : la position géographique influence très peu la gravité des accidents individuellement.

3. Gravité par État (Boxplots et ANOVA)

- Comparaison des 5 États les plus accidentés via boxplots et ANOVA.
- Résultat ANOVA : $F \approx 4946$, $p < 0,001$ → **différences significatives de gravité entre États**.
- **Observation** : certains États présentent des accidents plus graves en moyenne, probablement liés à la densité routière et aux infrastructures.

4. Probabilité d'accidents graves selon la position

- Régression logistique : $\text{Severe_Accident} \sim \text{Start_Lat} + \text{Start_Lng}$
- Résultat : coefficient Latitude positif, Longitude négatif, tous deux significatifs.
- **Interprétation** : certains secteurs géographiques présentent **une probabilité légèrement plus élevée d'accidents graves**, même si l'effet global reste faible (Pseudo $R^2 \approx 0,0037$).

5. Clustering géographique (KMeans)

- Quatre clusters ont été identifiés sur la base de Latitude, Longitude et Severity.

- **Insights :**
 - Existence de **zones “hotspots”** d’accidents concentrés.
 - Certains clusters regroupent des accidents plus graves que d’autres.

6. Densité géographique des accidents

- Hexbin plot / heatmap :
 - Forte densité dans les **grandes villes et zones urbaines**.
 - Répartition très **non uniforme**, avec des zones rurales plus éparées.

7. Top 10 villes les plus accidentées

- Houston, Los Angeles, New York... concentrent plus de **5% des accidents chacun**.
- Les 10 premières villes représentent **environ 25% du total** des accidents.
- **Interprétation :** les mégapoles concentrent une part importante du risque.

8. Analyse combinée Géographie + Météo (ACP)

- PCA sur Latitude, Longitude, Température, Humidité, Vent et Visibilité.
- **Insights :**
 - Permet d’identifier **des profils d’accidents liés à la combinaison de facteurs géographiques et environnementaux**.
 - Utile pour visualiser **zones et conditions à risque élevé**.

9. Conclusion Géographique

- Les accidents sont fortement concentrés dans **certaines zones urbaines et États spécifiques**.
- Bien que la position géographique seule ait un effet limité sur la gravité, la **combinaison de facteurs géographiques, météorologiques et infrastructurels** permet de mieux identifier les **zones à risque élevé**.
- Cette analyse complète les études temporelles et météorologiques pour **orienter les politiques de prévention et d’urbanisme routier**.

III Analyse de l'influence des infrastructures routières sur la gravité des accidents

Cette analyse vise à étudier l'impact des infrastructures routières sur la fréquence et la gravité des accidents de la route aux États-Unis. Les variables étudiées incluent plusieurs types d'infrastructures telles que les carrefours (Junction), les feux de signalisation (Traffic_Signal), les passages piétons (Crossing), les ronds-points (Roundabout), les voies ferrées (Railway) et autres équipements routiers.

1. Répartition des accidents par type d'infrastructure

L'analyse de la distribution montre que les accidents sont **majoritairement associés à certaines infrastructures spécifiques**, notamment :

- Les **carrefours (Junction)**,
- Les **feux de signalisation (Traffic_Signal)**,
- Et les **passages piétons (Crossing)**.

Cette concentration s'explique par le fait que ces zones sont caractérisées par une forte interaction entre véhicules, piétons et signalisations, augmentant ainsi la probabilité d'accidents.

2. Gravité des accidents et infrastructures

Les boxplots réalisés pour chaque type d'infrastructure indiquent que :

- Certaines infrastructures, comme les **carrefours**, les **voies ferrées** et les **zones de ralentissement du trafic**, sont associées à une **variabilité plus élevée de la gravité**, incluant des accidents plus sévères ;
- D'autres infrastructures, telles que les **ronds-points**, présentent globalement une gravité plus modérée, suggérant un effet potentiel de régulation de la vitesse.

3. Corrélation entre infrastructures et gravité

La matrice de corrélation de Spearman entre les infrastructures et la variable **Severity** met en évidence :

- Des **corrélations faibles**, mais parfois statistiquement significatives, entre certaines infrastructures et la gravité des accidents ;
- L'absence de corrélation forte, indiquant que la présence d'une infrastructure seule n'explique pas entièrement la gravité, mais qu'elle agit en interaction avec d'autres facteurs (météo, trafic, environnement urbain).

4. Comparaison accidents avec et sans infrastructure

La comparaison entre les accidents survenus à **proximité d'infrastructures** et ceux survenus **en leur absence** montre que la majorité des accidents ont lieu près d'équipements routiers structurants. Cela souligne le rôle central de ces zones comme points critiques du réseau routier.

5. Analyse spatiale des accidents liés aux infrastructures

La cartographie par heatmap des accidents situés à proximité des **carrefours** révèle une **forte concentration géographique**, principalement dans les zones urbaines et périurbaines. Cette distribution confirme que les infrastructures complexes constituent des zones à risque élevé.

6. Conclusion de l'analyse des infrastructures

Dans l'ensemble, cette analyse montre que :

- Les infrastructures routières jouent un rôle important dans la **fréquence des accidents** ;
- Leur impact sur la **gravité** est réel mais reste modéré lorsqu'il est analysé isolément ;
- Les zones équipées d'infrastructures complexes (carrefours, signalisations, passages piétons) doivent être considérées comme des **zones prioritaires pour la prévention routière**.

Ces résultats suggèrent que l'amélioration de la conception et de la gestion des infrastructures, combinée à d'autres facteurs explicatifs, pourrait contribuer significativement à la réduction des accidents graves.